

Understanding Semantic Change of Words Over Centuries



Jairo

Modelagem

O TIME

Mayza

Análise e apresentação

Rafael

Análise e apresentação

Rodrigo

Coleta e modelagem



Understanding Semantic Change of Words Over Centuries

Derry Tanti Wijaya
Language Technologies Institute
Carnegie Mellon University
5000 Forbes Ave.
Pittsburgh, PA 15213
dwijaya@andrew.cmu.edu

Reyyan Yeniterzi
Language Technologies Institute
Carnegie Mellon University
5000 Forbes Ave.
Pittsburgh, PA 15213
reyyan@cs.cmu.edu

ABSTRACT

In this paper, we propose to model and analyze changes that occur to an entity in terms of changes in the words that co-occur with the entity over time. We propose to do an in-depth analysis of how this co-occurrence changes over time, how the change influences the state (semantic, role) of the entity, and how the change may correspond to events occurring in the same period of time. We propose to identify clusters of topics surrounding the entity over time using Topics-Over-Time (TOT) and k-means clustering. We conduct this analysis on Google Books Ngram dataset. We show how clustering words that co-occur with an entity of interest in 5-grams can shed some lights to the nature of change that occurs to the entity and identify the period for which the change occurs. We find that the period identified by our model precisely coincides with events in the same period that correspond to the change that occurs.

contexts, the meanings of the words change gradually, often to the point that the new meaning is radically different from the original usage. For example, awful ¹ originally meant 'awe-inspiring, filling someone with deep awe', as in the awful majesty of the Creator. At some point it becomes something extremely bad, as in an awfully bad performance, but now the intensity of the expression has lessened and the word is now used informally to just mean 'very bad', as in an awful mess. Some words also change semantically, not in their original meanings but change in a way that they acquire additional meanings or are used to refer to other named entities over time. For example, mouse is used originally to refer to small long-tailed animal but it is now also used to refer to a device used to control cursor movement.

Automatically identifying changes to an entity over time is beneficial to many natural language applications. For example, for a macro-reader ² that gathers 'background/commonsense' facts about entities from a large collection of input

Sobre o artigo:

 2011 - Conference on Information and Knowledge Management da ACM (ACM - CIKM), Escócia

 DETECT - DETecting and Exploiting Cultural diversiTy on the Social Web

Análise semântica de diferentes períodos

 Essa identificação dos temas que circundam a entidade analisada é feita através da análise de Tópicos ao Longo do Tempo (Topics-Over-Time, TOT) e K-means Clustering




Dataset: Google N-Gram

- 5-gramas em aprox. 800 arquivos de 1 GB.
- Nossa amostra:
 - Woman: 1,07 mi 5-gramas ~35MB
 - Man: 4,4 mi 5-gramas. ~130MB

Modelagem de tópicos

- PLN n\u00e3o supervisionada
- Documentos podem ser considerados uma coletânea de tópicos
- Análogo a clusterização, mas com combinações de palavras.


Detecta a temática oculta do texto



Latent Dirichlet Allocation




LDA



- 1. Aloca aleatoriamente um tópico para cada palavra
- 2. Para cada documento d:
 - a. Assume que todos tópicos alocados estão corretos, exceto para d
 - b. Calcula:
 - i. Proporção de palavras no documento d que estão alocadas ao tópico t. t = p(topico t | documeto d)
 - ii. Proporção de alocações ao tópico t em relação a todos documentos relacionados a palavra w. w = p(palavra w | topico t)
 - iii. t * w para alocar w a um novo tópico. Repete até chegar a um estado estável.


Processamento: Para woman e man

- Seleciona as 2 palavras prévias e posteriores
- Criação de corpus para cada século
- Remoção caracteres [^A-Za-z]
- Transformação em minúsculas
- Tokenização
- Remoção Stopwords
- PorterStemmer
- Bag of Words
- Tf-idf
- LDA




Palavras mais comuns

As palavras mais comuns não variam muito entre gênero no dataset




Old, Honest, Young, Woman, Came


Man



Tópicos desbalanceados





Variamos o número de tópicos de 3 a 7, porém os resultados continuaram desbalanceados



Porém verificamos variações interessantes. Homens estão mais relacionados a características externas e mulheres a questões internas/pessoais (ex: direitos)


Detecção do número de tópicos





Curiosidades e limitações

O principal tópico relacionado a mulheres tem o termo sufrágio. Isso abre espaço para discutir o desbalanceamento dos dados no tempo.



Em uma das modelagens LDA para woman (n_topics = 3, anos=ALL, vectorizer=TF), **african** era o 3° termo mais importante do primeiro tópico (47,3%) e **white** o 5° principal do segundo (40,5%)

Problemas no TFIDF: $VolCount(t) \approx totalWords_t/aveWordsPerVolume_t$ $\approx \sum_x Match_t(x)/[(1/|x|) * \sum_x Match_t(x)/Vol_t(x)]$

Variação de Tópicos ao longo dos séculos

VB = 9 ADJ = 17 (65%)

Woman

```
1500: 0.200*"honest" + 0.080*"love" + 0.080*"told" + 0.080*"infam" + ...

1600: 0.049*"born" + 0.037*"ask" + 0.037*"forget" + 0.037*"hath" + 0.037*"love" + 0.037*"honest"

1700: 0.028*"beauti" + 0.027*"young" + 0.025*"honest" + 0.021*"bond" + 0.020*"amiabl" + ...

1800: 0.028*"beauti" + 0.028*"young" + 0.013*"love" + 0.013*"born" + 0.013*"everi" + 0.013*"whose"

1900: 0.023*"young" + 0.019*"elderli" + 0.019*"ask" + 0.018*"older" + 0.016*"attract" + 0.016*"beauti"

2000: 0.023*"young" + 0.017*"anoth" + 0.017*"beauti" + 0.016*"ask" + 0.015*"elderli" + 0.015*"older"
```

Variação de Tópicos ao longo dos séculos

VB = 12 ADJ = 10 (45%)

Man

```
1500: 0.077*"honest" + 0.036*"great" + 0.036*"everi" + 0.036*"english" + 0.027*"might" + 0.019*"say" + ...

1600: 0.060*"everi" + 0.054*"honest" + 0.025*"great" + 0.021*"may" + 0.019*"bodi" + 0.015*"good" + ...

1700: 0.067*"everi" + 0.043*"honest" + 0.017*"good" + 0.015*"may" + 0.013*"great" + 0.012*"anoth" + ...


1800: 0.045*"everi" + 0.020*"honest" + 0.011*"call" + 0.011*"could" + 0.011*"anoth" + 0.010*"would" + ...


1900: 0.024*"everi" + 0.015*"anoth" + 0.013*"honest" + 0.012*"could" + 0.011*"ask" + 0.011*"woman" + ...

2000: 0.023*"everi" + 0.016*"anoth" + 0.012*"could" + 0.011*"call" + 0.011*"becom" + 0.011*"ask" + ...
```

Conclusões

- Enquanto que algumas palavras tem seu significado modificado ao longo dos séculos, outras mantém associadas a palavras similares.
- Assim como god, woman se encaixa nesse grupo de palavras estáticas. Apesar disso, detectamos algumas variações ao longo dos séculos, mas podem ser apenas resultante de sub-amostragem pois isso ocorreu comparando séculos 15, 16 e 20.
- Palavras associadas a homem e mulher, similares quanto a beleza e juventude.
- Honestidade aparece mais associada a homem.
- O trabalho original reporta apenas clusters selecionados manualmente em comparações pareadas, o que pode indicar algum viés de seleção.





Bibliotecas utilizadas

Google_ngram_downloader - Dataset

Nltk - tokenização, stopwords, PorterStemmer

Re

Seaborn e pyLDAvis - Visualização

Sklearn - LDA, CountVectorizer, TfidfVectorizer

Gensim - LDA, tf-idf

Vocab, man = 9234 / woman = 3637



